

BÁO CÁO TRỰC QUAN HÓA, PHÂN TÍCH DỮ LIỆU VÀ MÔ HÌNH DỰ BÁO DOANH THU

Thái Mạc Tường Vi Nguyễn Tuấn Khang Dương Thành Tài
tuongvi.work.2327@gmail.com khangvuive2007@gmail.com study.duongthanhtai@gmail.com

Abstract

Báo cáo này được thực hiện bởi đội thi **Tây Thạnh** trong khuôn khổ cuộc thi **Datathon 2026 - The Gridbreakers** do câu lạc bộ **Vintelligence** trực thuộc **VinUniversity** tổ chức. Nội dung nghiên cứu tập trung vào việc *trực quan hóa*, *phân tích sâu hành vi khách hàng* và *xây dựng mô hình dự báo doanh thu* cho doanh nghiệp dựa trên dữ liệu giai đoạn 2012 - 2022. Thông qua các phương pháp phân tích, nhóm đã xác định được sự lệch pha giữa lưu lượng truy cập và hiệu quả chuyển đổi doanh thu thực tế. Bằng cách áp dụng phân cụm khách hàng với ngưỡng động, báo cáo chỉ ra các nhóm khách hàng cốt lõi cùng những rủi ro về tỷ lệ hoàn hủy và sự phụ thuộc vào các chu kỳ khuyến mãi. Cuối cùng, chúng tôi đề xuất một quy trình dự báo sử dụng thuật toán XGBoost kết hợp với các chiến lược ổn định hóa sai số, nhằm cung cấp một công cụ dự đoán dòng tiền bền vững và chính xác, hỗ trợ doanh nghiệp trong việc tối ưu hóa vận hành và hoạch định chiến lược kinh doanh dài hạn.


Mã nguồn công khai: [TayThanh_Datathon_2026](#)

Mục lục

1	Trực quan hoá và Phân tích Dữ liệu	3
1.1	Dữ liệu lưu lượng truy cập website hàng ngày	3
1.1.1	Observation	3
1.1.2	Insight	3
1.1.3	Implication	3
1.2	Các phân khúc Khách hàng và hiệu ứng chu kỳ khuyến mãi	3
1.2.1	Phương pháp phân cụm khách hàng và chu kỳ khuyến mãi	3
1.2.2	Phân tích tổng quan các phân khúc khách hàng	4
1.2.3	Phân tích độ nhạy của khách hàng với chu kỳ khuyến mãi	4
2	Mô hình dự báo doanh thu	5
2.1	Phương pháp tiếp cận và Pipeline mô hình	5
2.2	Chiến lược kiểm chứng và Tính tái lập	6
2.3	Dự báo đệ quy và Chiến lược Blending	6
2.4	Giải thích mô hình và Kết quả thực nghiệm	6
3	Phụ lục	7

1 Trục quan hoá và Phân tích Dữ liệu

1.1 Dữ liệu lưu lượng truy cập website hàng ngày



Biểu đồ 1 - Tương quan giữa xu hướng truy cập web và doanh thu

1.1.1 Observation

Biểu đồ cho thấy lưu lượng truy cập web có xu hướng tăng dần theo thời gian, đặc biệt từ sau năm 2019, trong khi doanh thu không tăng tương ứng mà có xu hướng chững lại. Khoảng cách giữa hai đại lượng ngày càng lớn. Ngoài ra, các chu kỳ lặp lại theo năm thể hiện yếu tố mùa vụ rõ rệt, và một số đỉnh traffic không đi kèm với sự gia tăng doanh thu.

1.1.2 Insight

Điều này cho thấy hiệu quả chuyển đổi đang suy giảm, tức là việc gia tăng lưu lượng truy cập không còn mang lại mức tăng tương ứng doanh thu tương xứng. Đồng thời, sự xuất hiện của các đỉnh traffic không đi kèm doanh thu cũng hàm ý sự tồn tại của nguồn truy cập có chất lượng thấp.

1.1.3 Implication

Kết quả này gợi ý rằng việc chỉ tập trung tăng lưu lượng truy cập là chưa đủ để tối ưu doanh thu. Doanh nghiệp cần chú trọng hơn vào việc nâng cao chất lượng traffic và tối ưu hóa trải nghiệm người dùng nhằm cải thiện tỷ lệ chuyển đổi. Đồng thời, các yếu tố thời gian (như mùa vụ) cũng nên được đưa vào mô hình dự báo để tăng độ chính xác.

1.2 Các phân khúc Khách hàng và hiệu ứng chu kỳ khuyến mãi

Trong phần này, doanh thu thực được định nghĩa là tổng doanh thu trừ khi số tiền hoàn trả do đơn bị hủy hoặc bị hoàn trả.


1.2.1 Phương pháp phân cụm khách hàng và chu kỳ khuyến mãi

Logic Phân khúc Khách hàng: Khách hàng được định danh thành 6 nhóm điều kiện và 1 nhóm mặc định (**loyal**). Trong đó, *ngưỡng động (Dynamic Thresholds)* với $quantity = 70\%$ được sử dụng để phân loại khách hàng chất lượng cao. Cụ thể theo logic điều kiện phân tầng như sau:

- (1) **non_buyer:** 0 đơn hàng, phân loại này được **loại bỏ** hoàn toàn trong các phân tích doanh thu để tránh làm nhiễu dữ liệu trung bình ;
- (2) **new_customer:** Gia nhập hoặc phát sinh đơn đầu tiên ≤ 6 tháng và ≤ 2 đơn hàng ;
- (3) **low_quality:** Tỷ lệ hoàn/hủy $\geq 75\%$ hoặc giá trị thực trả $< 50\%$;
- (4) **old_customer:** Lần mua cuối $< 31/12/2019$;
- (5) **high_value_loyal:** Phát sinh > 1 đơn hàng và tỷ lệ hoàn/hủy $< 30\%$ và giá trị thực trả $\geq$ ngưỡng động của tất cả khách hàng và lần mua cuối vẫn nằm trong chu kỳ mua trung bình ;
- (6) **at_risk:** Tỷ lệ hoàn/hủy $\geq 50\%$ hoặc lần mua cuối $> 1,5$ lần chu kỳ mua trung bình.

Phát hiện chu kỳ khuyến mãi: Theo *Biểu đồ 8*, trong suốt giai đoạn 2013 - 2022, doanh nghiệp duy trì một lịch trình khuyến mãi có tính lặp lại định kỳ rất cao với 6 chiến dịch chính. Việc xác định được 6 khoảng thời gian này giúp phân biệt rõ giữa tăng trưởng doanh thu tự nhiên và hiệu ứng do kích cầu.

1.2.2 Phân tích tổng quan các phân khúc khách hàng



Biểu đồ 2 - Số lượng và doanh thu thực theo từng phân khúc khách hàng

Biểu đồ 2 cho thấy có sự **chênh lệch lớn** giữa *quy mô* phân khúc khách hàng và *mức đóng góp doanh thu thực*. Nhóm **old_customer** có số lượng đông nhất (29.4%) nhưng chỉ đóng góp **17.0%** tổng doanh thu. Ngược lại, hai nhóm mang lại doanh thu cốt lõi là **at_risk** (cao nhất, chiếm **31.9%** doanh thu) và **high_value_loyal** (29.9%) dù số lượng người dùng chỉ ở mức trung bình (tương ứng 12.8% và 9.6%).

Nguyên nhân nhóm **at_risk** mang lại doanh thu cao nhất nhưng được xếp vào diện rủi ro là vì:

Đối chiếu với *Biểu đồ 4*, nhóm **at_risk** có tỷ lệ hoàn/hủy khá cao (**14.5%**) cùng số lượng đơn hoàn/hủy lớn nhất (**31,204** đơn).

Đáng chú ý, *Biểu đồ 6* và *Biểu đồ 7* cho thấy phân phối lý do trả hàng (chủ yếu sai kích cỡ ~**35%**) và đánh giá (**hơn 70%** là 4-5 sao) gần như đồng nhất giữa tất cả các phân khúc. Điều này chứng tỏ vấn đề **không** nằm ở chất lượng sản phẩm, mà do đặc thù hành vi mua sắm bốc đồng khối lượng lớn của nhóm **at_risk** dẫn đến tỷ lệ đổi trả cao theo quy mô. Đồng thời, nhóm **low_quality** có tỷ lệ hủy/hoàn lên tới mức báo động **72.9%**, gây lãng phí chi phí vận hành dù doanh thu đóng góp chưa tới **1%**.

Nếu không có sự can thiệp, doanh nghiệp có nguy cơ đối mặt với sự sụt giảm doanh thu trong tương lai gần. Phân khúc **at_risk** - *con gà đẻ trứng vàng* với 31.9% doanh thu - đang có dấu hiệu **kéo dài thời gian giữa các lần mua** theo định nghĩa phân khúc. Việc rời bỏ của nhóm này sẽ để lại khoảng trống tài chính mà nhóm **new_customer** (chỉ chiếm **0.9%** doanh thu) không thể bù đắp được. Chính vì vậy:

Đối với nhóm **at_risk**: Cần triển khai ngay các chiến dịch Remarketing được cá nhân hóa, cung cấp voucher hoặc đặc quyền chăm sóc riêng để kéo họ quay lại chu kỳ mua sắm định kỳ.


Đối với nhóm **low_quality**: Doanh nghiệp cần thiết lập chính sách hoàn trả chặt chẽ hơn (ví dụ: thu phí vận chuyển chiều về đối với khách hàng có lịch sử hoàn $\geq 50\%$).

Về lý do trả hàng: Cần cải thiện bảng hướng dẫn chọn size chuẩn xác cùng với vận hành chặt chẽ hơn nhằm đảm bảo trải nghiệm mua sắm cho khách hàng, nâng cao chất lượng uy tín và cắt giảm chi phí logistics rỗng do trả hàng vì **wrong_size**.

1.2.3 Phân tích độ nhạy của khách hàng với chu kỳ khuyến mãi

Trong biểu đồ này, nhóm sẽ gộp các phân khúc khách hàng thành hai nhóm chính: nhóm **new_customer** & **low_quality** (do hai nhóm này đóng góp chưa tới 2% vào tổng doanh thu thực tế); và nhóm còn lại tập hợp những phân khúc khách hàng lại nhằm nhìn rõ hành vi mua sắm.

Biểu đồ 3 cho thấy sự khác biệt rõ rệt giữa các đợt khuyến mãi. Trong khi **Spring Sale** và **Urban Blowout** đóng vai trò là *đòn bẩy* mạnh mẽ kéo doanh thu lên (**2.2 - 2.8 triệu VNĐ/ngày**), thì **Mid-year Sale** và **Year-End Sale** lại trở thành *điểm trũng* khi doanh thu thực tế đang chạm đáy thấp nhất năm (**0.3 – 0.5 triệu VNĐ/ngày**).



Biểu đồ 3 - Doanh thu thực trung bình mỗi ngày trong năm

Tuy nhiên, khi nhìn một cách tổng thể, các đỉnh doanh thu cao nhất (vượt ngưỡng **3 triệu VNĐ/ngày**) thực tế lại rơi vào giai đoạn *vùng trắng* không khuyến mãi trong khoảng cuối tháng 4 - cuối tháng 5. Điều này cho thấy doanh nghiệp đang sở hữu một chu trình doanh thu tự nhiên vô cùng mạnh mẽ. Có khả năng chiến dịch **Spring Sale** đạt doanh thu cao chủ yếu nhờ được mở ra đúng vào giai đoạn nhu cầu tiêu dùng bắt đầu tăng tốc để chuẩn bị cho đợt đỉnh điểm tự nhiên ngay sau đó.

Biểu đồ 9 cũng cho thấy các đỉnh tự nhiên cuối tháng 4 - cuối tháng 6 đã duy trì bền vững suốt 10 năm qua với mô hình *răng cưa*. Việc cố gắng kích cầu vào các giai đoạn thị trường đang bão hòa hoặc có xu hướng thắt chặt (như dịp cuối năm) dự báo sẽ tiếp tục gây lãng phí ngân sách và không mang lại dòng tiền thực hiệu quả

Chính vì vậy, thay vì duy trì các chương trình giảm giá dàn trải, doanh nghiệp nên xây dựng lại lộ trình khuyến mãi dựa trên nhịp mua sắm tự nhiên. Cần tập trung nguồn lực lớn nhất để đón đầu và cộng hưởng cùng đỉnh doanh thu. Đồng thời, nên chuyển dịch ngân sách từ các chiến dịch giảm giá kém hiệu quả sang các chương trình chăm sóc khách hàng đặc quyền để bảo vệ biên lợi nhuận trong những giai đoạn thấp điểm.

2 Mô hình dự báo doanh thu

2.1 Phương pháp tiếp cận và Pipeline mô hình

Trong bài toán này, chúng tôi tiếp cận theo hướng dự báo chuỗi thời gian đa biến. Thuật toán chủ đạo được lựa chọn là **XGBoost** (Extreme Gradient Boosting) nhờ khả năng nắm bắt hiệu quả các xu hướng phi tuyến tính và xử lý tốt dữ liệu bảng có độ nhiễu cao.

Quy trình xử lý (*Pipeline*) của chúng tôi gồm:

Feature Engineering:

Biến trễ (Lag Features): Trích xuất các biến trễ như `rev_lag_1`, `profit_lag_7`, `profit_lag_365`, `margin_rate_lag_7` và `_page_views_lag_365`,... để mô hình nắm bắt xu hướng và tính mùa vụ.

Biến lịch (Calendar Features): Sử dụng `day_of_week`, `is_weekend` và `month` để mô hình hiểu được các chu kỳ thời gian.

Biến khuyến mãi (Promotion Features) và Mùa vụ (Seasonality): Thay vì tổng quát hóa, nhóm quyết định giữ nguyên các biến one-hot riêng lẻ đại diện cho từng chiến dịch cụ thể (ví dụ: `is_Spring_promotion`, `is_MidYear_promotion`, `is_YearEnd_promotion`...). Kết hợp cùng đặc trưng thời gian theo Quý (quarter), phương pháp này giúp thuật toán XGBoost nhận diện chính xác sự cộng hưởng giữa tính chu kỳ của thị trường và sức hút của từng sự kiện riêng biệt. Thực tế phân tích Feature Importance xác nhận các biến khuyến mãi cụ thể này vẫn đóng góp vai trò quan trọng, hoạt động như những tín hiệu kích hoạt (trigger) giúp mô hình dự báo chính xác các đỉnh bùng nổ doanh thu trong năm.

Biến danh mục (Category Features): One-Hot Encoding cho category và segment sản phẩm, kết hợp với avg_discount_pct và max_discount_pct.

Hyperparameter Tuning:

Sử dụng thư viện **Optuna** với thuật toán TPE để tự động tìm kiếm bộ tham số tối ưu cho XGBoost trong 50 lần thử nghiệm. Không gian tìm kiếm bao gồm n_estimators, max_depth, learning_rate, subsample, colsample_bytree, reg_alpha và reg_lambda, với hàm mục tiêu là RMSE trên tập validation.

2.2 Chiến lược kiểm chứng và Tính tái lập

Để đáp ứng yêu cầu khắt khe về tính khách quan, chúng tôi áp dụng kỹ thuật **TimeSeriesSplit** với 5-fold cross-validation. Toàn bộ mã nguồn được đính kèm tại GitHub repository, đảm bảo tính tái lập (*Reproducibility*) thông qua việc thiết lập random_seed cố định cho tất cả các tiến trình ngẫu nhiên. Chúng tôi khẳng định không sử dụng dữ liệu bên ngoài bộ dữ liệu được cung cấp.

2.3 Dự báo đệ quy và Chiến lược Blending

Trong giai đoạn dự báo cho năm 2023-2024, nhóm áp dụng phương pháp **Recursive Forecasting** (dự báo đệ quy), cho phép mô hình sử dụng kết quả dự báo của bước trước làm đầu vào cho bước tiếp theo. Ưu điểm của phương pháp này là tính linh hoạt và khả năng tận dụng tối đa các đặc trưng độ trễ. Tuy nhiên, một nhược điểm chí mạng là hiện tượng **sai số tích lũy** (*cumulative error propagation*), khi các sai lệch nhỏ ở những bước đầu tiên bị khuếch đại theo thời gian, dẫn đến quỹ đạo dự báo bị lệch hướng.

Để giảm thiểu sai số này, chúng tôi triển khai chiến lược **Blending** giữa dự đoán của mô hình với xu hướng trung bình trượt 365 ngày từ dữ liệu lịch sử. Việc kết hợp này giúp "neo" dự báo vào thực tế lịch sử, từ đó ổn định hóa kết quả đầu ra. Thông qua việc thử nghiệm trên tập kiểm thử năm 2022 để có thể dự đoán đúng xu hướng của một năm, chúng tôi đã thực hiện tối ưu hóa vòng lặp cho hai tham số: growth_factor và tỷ lệ blending.


Mặc dù kết quả tối ưu cục bộ trả về bộ tham số 0.96 và tỷ lệ 70/30 (đạt $R^2 = 0.96$), nhóm quyết định lựa chọn bộ tham số 1.15 và tỷ lệ cân bằng 70/30. Quyết định này nhằm ưu tiên tính bền vững (*robustness*) của mô hình giúp dự đoán đúng về xu hướng tăng trưởng, tránh việc quá khớp (*overfitting*) vào các biến động đặc thù của năm 2022, từ đó đảm bảo khả năng dự báo đáng tin cậy cho toàn bộ giai đoạn dài hạn phía trước.

2.4 Giải thích mô hình và Kết quả thực nghiệm


Chúng tôi sử dụng biểu đồ tầm quan trọng đặc trưng (*Feature Importance*) dựa trên chỉ số **Gain** để giải thích mô hình. Kết quả cho thấy doanh thu của ngày liền trước (rev_lag_1) là yếu tố dẫn động chính, cho thấy tính phụ thuộc cao của doanh thu vào phong độ bán hàng ngắn hạn. Hiệu suất mô hình được tổng hợp tại Bảng 1.

Bảng 1: Kết quả đánh giá mô hình trên tập Cross-validation		
Mục tiêu dự báo	RMSE (Root Mean Squared Error)	Hệ số xác định (R^2)
Doanh thu (Revenue)	476,399.37	0.9624
Giá vốn (COGS)	352,486.55	0.9674


3 Phụ lục




Biểu đồ 4 - Số lượng và tỷ lệ hoàn/hủy đơn theo phân khúc khách hàng



Biểu đồ 5 - Phân bố khu vực theo phân khúc khách hàng




Biểu đồ 6 - Phân bố lý do trả hàng theo phân khúc khách hàng




Biểu đồ 7 - Phân bố đánh giá sản phẩm theo phân khúc khách hàng

PHÂN TÍCH CHU KỲ CÁC CHIẾN DỊCH GIẢM GIÁ (Giai đoạn 2013 - 2022)



Biểu đồ 8 - Phân tích chu kỳ các chiến dịch giảm giá

XU HƯỚNG DOANH THU THỰC THEO PHÂN KHÚC KHÁCH HÀNG (Chu kỳ 2 tuần | Giai đoạn 2013 - 2022)



Biểu đồ 9 - Xu hướng doanh thu thực theo phân khúc khách hàng